

Short meeting

2.10

Agenda

- Experiment results and some conclusions based on four prior forms from the directory of prior (on synthetic dataset; few instance scenario)
- Possibility of ST-PT applied in Conditional Time Series Generation
- Some ideas about the 'philosophy' of modeling modification in 'ST-PT' (immature)
- Further explorations & Things I want to write into the arxiv report

Experiment of four priors on synthetic data - Period


- 构造思想是用不同通道模拟“从简单到复杂、从干净到含噪”的周期模式：每个样本都会随机采样一个全局相位 `phase_shift`（保证不同样本相互独立），然后生成基础周期（P24、P12、P48）、谐波叠加（ $P24+0.5 \cdot P12$ ）、拍频（ $P24+P20$ ），再在这些信号上分别叠加白噪声或红噪声（AR(1) 相关噪声）来测试鲁棒性；最后还有一个纯红噪声通道作为对照。整体目的是让模型在同一数据集中同时面对清晰周期、频率变化、叠加结构、拍频现象以及噪声干扰。
- Few instance: 150个样本进行学习（当然我也做了1500, 15000个样本的实验）
- All models: same `d_model` and `d_ff` (64, 128), same and appropriate learning rate, no patching (patch len = 1), one head

Experiment of four priors on synthetic data - Period


$$\phi_t(H_{ij}, \underbrace{Z_{ij}, Z_{ik}}_{\text{same channel}}) = \begin{cases} \exp\left(\lambda \cos\left(\frac{2\pi(i-j)}{T/\text{patch-size}}\right) \cdot T(z_{ij}, z_{ik})\right) & H_{ij} = ik \\ 1, & \text{else.} \end{cases}$$

mse \ model	ST-PT original	ST-PT period (lambda = 5)	iTransformer	PatchTST
150 samples	0.230	0.222	0.580	0.250
1500 samples	0.216	0.213	0.221	0.238
15000 samples	0.194	0.195	0.193	0.201

150 Samples Visualization - 上: ST-PT 下:ST-PT period



150 Samples Visualization - 左: ST-PT 右:ST-PT period



图上看的可能不明显，但是我充分观察发现：高频尖峰预测顶地更靠上面了（而这是周期预测中的小痛点）

Experiment of four priors on synthetic data - Trend

trend 是一个用于**趋势外推 (long-term forecast)**的合成多变量数据集，保存为 .npy，形状 (N, 192, 10)：每条样本前 96 步作为输入、后 96 步作为预测目标 (Input 96 $\rightarrow$ Output 96)。

构造方式/思想：把时间 t 归一化为 $t_norm=t/96$ (使输入段落在 $[0,1]$ 、输出在 $[1,2]$)，然后在 10 个通道里刻意放入不同“趋势曲率”类型，并对每个样本随机扰动斜率/曲率保证 IID：

0-2 通道：线性/缓慢漂移（零曲率基线）；

3-6 通道：凸增长/加速（正曲率：二次、指数、三次，以及被强红噪声掩盖的二次加速）；

7-9 通道：凹增长/趋于饱和（负曲率：log、sqrt、倒数型饱和）。

最后再加少量全局白噪声避免“完美曲线”过拟合。整体目的是检验模型是否能从输入段识别**斜率与曲率（动量）**并对未来做合理外推，而不是只做平滑延长。

Few instance: 150个样本进行学习（当然我也做了1500, 15000个样本的实验）


All models: same d_model and d_ff (64, 128), same and appropriate learning rate, no patching (patch len = 1), one head

Experiment of four priors on synthetic data - Trend

② Trend


同 channel

(Decode μ M & z).



mse \ model	ST-PT original	ST-PT trend	iTransformer	PatchTST
150 samples	0.611	0.497	1.779	0.625
1500 samples	0.113	0.080	0.459	0.164
15000 samples	0.064	0.061	0.065	0.115

1500 Samples Visualization - 左: ST-PT 右:ST-PT trend




趋势拟合有了trend建模更好

Experiment of four priors on synthetic data - Lag

- 每条样本包含 3 组“源→目标”的严格因果结构，目标通道几乎就是源通道延迟 τ 步后的函数/拷贝（再加少量噪声），从而形成明确可验证的因果滞后：
- Ch0 → Ch1：带慢变包络的正弦（源）→ 延迟 τ 的拷贝（目标）。
- Ch2 → Ch3：周期性脉冲（源）→ 在 τ 后触发的阶跃累积响应（目标）。
- Ch4 → Ch5：锯齿波（源）→ 线性变换 $m*x+b$ 后再延迟 τ （目标）。
- 整体目的是在可控环境下评估模型是否能从多通道序列中学习“哪一对通道相关、以及延迟多少步 τ ”这种跨通道滞后依赖，而不是只做同通道的自回归拟合。

Experiment of four priors on synthetic data - Lag


Channel A 效果延后 π 对 B 起作用:




mse \ model	ST-PT original	ST-PT lag	iTransformer	PatchTST
150 samples	0.261	0.219	0.654	0.295
1500 samples	0.021	0.019	0.235	0.049
15000 samples	0.0026	0.0023	0.235	0.009

Experiment of four priors on synthetic data - lag


Channel 1




Channel 1



Channel 3



Channel 3



150 samples

上: ST-PT original

下: ST-PT Lag

Experiment of four priors on synthetic data - Channel Dependency

- 使用lag数据集, $[[0, 1], [2, 3], [4, 5]]$


已知 Channel A, B之间相互独立

则 z_{Ai} z_{Bi} 间都不用 H 相连

影响不大，可能是因为H channel交互是所有通道之间的，包含了我们想要的允许信息交互的‘情况’

mse \ model	ST-PT original	ST-PT lag	iTransformer	PatchTST
150 samples	0.261	0.262	0.654	0.295
1500 samples	0.021	0.021	0.235	0.049
15000 samples	0.0026	0.0026	0.235	0.009

Possibility of ST-PT applied in Conditional Time Series Generation



- 为什么联想到了conditional time series generation? 、
- Pros: Prior很好给，那就是我们规定的生成条件。还有一个很好的Background，那就是condition的存在形式可以是attribute-form。它的formulation简而言之：一个attribute，比如说周期，趋势类型，每一个属性有一个value（e.g., 周期是4，趋势是linear and up），而这个value有一个固定的总集合（e.g. 周期是无？ 2？ 4？ ...）。
- 利用attribute-form condition的模型称为attr-based model
- Cons: 新的attribute需要新的建模，而且需要这个建模能够支持所有的value option，这个时候Y节点可能就有作用了。比如说固定有八种trend，那么M节点建模trend基础上，相邻M节点用ternary factor连接，并且有Y节点，Y连接一个observation trend type
- 就算最终ST-PT不target变成attr-based model，也可以尝试将启发的condition建模加到text-based model上，看是否能够加强（尤其是结合CFG算法，我们的module也许更有意义）

ST-PT => attr-based model ?

- 目前根据我的初步建模，如果Y节点的设计是一种合理的设计的话，那么在单通道合成数据集上，ST-PT(或者说PT)应该已经能够完全建模出一个attr-based model。(具体模型还要再思考和打磨)
- 这种attr-based model将会和现在的那些attr-based model在利用condition上非常的不一样，并且可能解决一些痛点（compositional OOD; fine-grained generation）
- condition as input => condition as inference
- 但是cons依然存在，也许有好的克服方式

**Some ideas about the ‘philosophy’ of modeling modification
in ‘ST-PT’ (immature)**

TODO

- More rigorous and supplementary experiments and visualizations on current synthetic data experiment of directory of priors to make sure our module plays an important role.
- Try to turn (ST-)PT into a attribute based model. Try to add some module (or modification) inspired by ST-PT to mature text-based model, seeking for performance improvement.
- Maybe Markove model module can be dually interpreted as the model modification to transformer to enhance its capability to capture underlying dynamic latent evolution. It will be better if NextLat released its codebase.

Things I want to put on the arxiv report


- Elaboration on PT modeling philosophy
- Introduction to ST-PT architecture
- Directory of prior synthetic experiment to demonstrate ST-PT modeling methodology
- Experiment about its expressivity using the task of forecasting and generation
- Apply some ST-PT-inspired modification to some transformer-based model in forecasting and conditional generation task

Transformer-based
model


ST-PT
modeling


Data set Prior
Granularity

task



Hard ST-PT Modeling: 1个 prior 具体形式对应 1个
具体 modeling (可能都是 一种 modeling 思路下的, 但
具体实现间不同).

如周期中: 若建模为 , T 有多个, 则
不利于 instance-wise training.

如 trend 不只一种, 若 , 则变相于逼迫
一套 M 节点与 1 factor 兼容多种 trend.

Soft: 一套建模表达这个 prior concept, 训练时具体


prior 不提供, 由建模拟合

如周期:



用“点与点间有关系”模拟能力.
包含周期性

如



多套(头)趋势建模.

(灵感来自于多头)

(可对应到 Transformer 中的修改) *

Firm: Dataset-Specific 下 泛化能力足够支持

Parallel Training & Inferencing (条件提供)

如周期: $\phi_t(H_i, z_i, z_j) = \int \exp\left(\cos\left(\frac{2\pi(i-j)}{T/\text{patch-size}}\right), T(z_i, z_j)\right)$

条件 / prior 具体形式 ($T = ?$) $\Rightarrow$ Period Bias Matrix